



МАТЕМАТИЧЕСКОЕ И ПРОГРАММНОЕ ОБЕСПЕЧЕНИЕ ДЛЯ ПРОГНОЗИРОВАНИЯ СВОЙСТВ МЕДИЦИНСКИХ КОМПОЗИЦИОННЫХ МАТЕРИАЛОВ

Выполнил: Шарыгин М.С., МО-425Б

Руководитель: Нургаянова О.С., к.т.н., доцент

1. Потребность стоматологии в ускорении разработки новых материалов с заданными свойствами для имплантатов, коронок, пломб и прочих конструкций;
2. Экономическая целесообразность – снижение затрат на проведение экспериментов за счёт предварительного компьютерного прогнозирования свойств материалов;
3. Уровень исследования вопроса – отсутствие открытых и доступных программных решений для прогнозирования свойств именно медицинских сплавов с возможностью интерактивного ввода состава и получения прогноза по нескольким свойствам одновременно;
4. Наличие экспериментальной базы сплавов – для исследования доступна выборка из 220 образцов стоматологических сплавов.



Цель и задачи ВКР

Цель: разработать математическое и программное обеспечения для прогнозирования свойств медицинских композиционных материалов.

Задачи:

1. Провести анализ предметной области и существующих программных решений для прогнозирования свойств медицинских композиционных материалов;
2. Исследовать возможные методы для решения задачи прогнозирования по химическому составу;
3. Разработать алгоритмическое и программное обеспечение для решения задачи «состав-свойство»;
4. Выполнить вычислительные эксперименты и тестирование разработанного программного обеспечения.

Обзор существующих решений

Программное решение	Краткое описание	Преимущества	Недостатки
JMatPro (Великобритания)	Рассчитывает широкий спектр физико-механических свойств	- Быстрые, точные и надежные расчеты; - Простота использования, - Онлайн-поддержка.	- Высокая стоимость лицензии; - Необходимо владеть специальными знаниями.
Thermo-Calc (Швеция)	Платформа для термодинамических и кинетических расчетов в материаловедении	Расчёт следующих свойств: - химических, - теплофизических, - упругости, - прочих.	Нужно покупать: - калькуляторы, - базы данных материалов.
Ansys GRANTA (США)	ПО для инженерного анализа и численного моделирования	Обширные базы данных: - материалов, - сплавов, - свойств.	- Стоимость лицензии; - Сложность применения.


Содержательная постановка задачи

Дано: набор структурированных патентных данных о составах и свойствах никель-хромовых композитов.


Требуется: по заданному химическому составу спрогнозировать следующие физико-механические свойства:

- « g » – плотность ($\text{г}/\text{см}^3$),
- « E » – модуль упругости (ГПа),
- « HV_{10} » – твердость по Виккерсу ($\text{кгс}/\text{мм}^2$),
- «КТР_{20–600}» – коэф. термического расширения при нагреве от 20 до 600 °С ($10^{-6}/\text{К}$),
- «КТР_{25–500}» – коэф. термического расширения при нагреве от 25 до 500 °С ($10^{-6}/\text{К}$).
- « Rm » – предел прочности (МПа),
- « $Rp_{0.2}$ » – предел текучести (МПа),
- « A_5 » – относительное удлинение (%),

Формальная постановка задачи



Структура решения



Дано:

- $X = (x_1, x_2, \dots, x_{21})$ – составы материалов – представлены в виде векторов из 21 химического элемента, где каждый элемент имеет массовую долю в процентах:
 - $x_1, x_2, \dots, x_{21}$ – концентрации элементов,
 - $x_1 \geq 60$,
 - $x_2 \geq 10$,
 - $x_i \geq 0: i = 3, 4, \dots, 21$,
 - $\sum_{i=1}^{21} x_i = 100$;
- $Y = (y_1, y_2, \dots, y_8)$ – свойства материалов – представлены в виде векторов из 8 свойств:
 - $y_1, y_2, \dots, y_8$ – значения свойств.

Найти:

- F – модель – целевая функция, которая переводит X в Y с минимальной ошибкой:
 - $F: X \rightarrow Y$;
 - $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \rightarrow \min$, где:
 - MAE – средняя абсолютная ошибка,
 - y_i – реальные значения свойств i -го образца,
 - $\hat{y}_i = F(x_i)$ – предсказанные значения свойств i -го образца, где x_i – состав i -го образца:
 - n – количество образцов в обучающей выборке.

Сравнение методов решения

Метод	Множественная линейная регрессия	Метод опорных векторов	Случайный лес	Искусственная нейронная сеть (ВЫБРАН)
Преимущества	- Интерпретируемость; - Простота; - Скорость; - Гиперпараметры.	- Устойчивость; - Ядро; - Выпуклость; - Простота реализации.	- Точность; - Устойчивость; - Масштабируемость; - Высокоразмерность.	- Универсальность; - Многомерность; - Гибкость; - Готовые библиотеки.
Недостатки	- Линейность; - Выбросы; - Мультикол-линеарность.	- Гиперпараметры; - Скорость; - Интерпретируемость.	- Интерпретируемость; - Вычислительная сложность; - Гиперпараметры.	- Гиперпараметры; - Длительность; - Интерпретируемость.


Модель – это ансамбль, состоящий из 8 одинаковых глубоких искусственных нейронных сетей, каждая из которых прогнозирует 1 из 8 свойств. Архитектура нейронной сети:

- Входной слой: 21 нейрон – по числу химических элементов;
- Скрытый слой: 256 нейронов (функция активации *ReLU*, *Dropout*(0.2));
- Скрытый слой: 128 нейронов (функция активации *ReLU*, *Dropout*(0.3));
- Скрытый слой: 64 нейрона (функция активации *ReLU*, *Dropout*(0.4));
- Скрытый слой: 32 нейрона (функция активации *ReLU*, *Dropout*(0.5));
- Выходной слой: 1 нейрон (линейная активация) – для прогнозирования одного свойства.


Параметры нейронной сети

- Линейная функция активации $f(x) = x$, где x – взвешенная сумма входных сигналов нейрона;
- Функция активации $ReLU = \max(0, x)$, где x – взвешенная сумма входных сигналов нейрона;
- $Dropout(p)$ – случайно выключает каждый нейрон слоя с вероятностью p ;
- Оптимизатор $Adam$ – корректирует веса нейронов;
- Функция потерь – среднеквадратическая ошибка $MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2$, где:
 - y_i – реальные значения;
 - $\hat{y}_i$ – предсказанные значения;
- Метрика – средняя абсолютная ошибка $MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$;
- Размер батча $batch_size = 32$, то есть обучающая выборка разделяется на блоки, содержащие по 32 неповторяющихся образца;
- Количество эпох $epochs = 100$ – нейросеть 100 раз полностью получает обучающую выборку;
- Ранняя остановка $early_stopping$ – останавливает процесс обучения, если MSE не улучшилась в течение 20 эпох;
- Разделение $validation_split = 0.2$ – разделяет обучающую выборку на обучающую и валидационную в отношении 80 на 20.


"Подготовка модели"




(1)




Алгоритм "Нормализация (train, test)"




Алгоритм "Аугментация (X, y, quantity, bias)"






Алгоритм "Тестирование (model, X_test_current, y_test_current)"



Алгоритм "Прогнозирование свойств"




Стек разработки

Разработка ПО осуществлена на «Python» – высокоуровневом языке, который является одним из самых популярных и востребованных для решения задач машинного обучения и обработки данных:

- Предобработка данных:
 - «Random»,
 - «OpenPyxl»,
 - «Pandas»,
 - «Joblib»,
 - «NumPy».
- Реализация нейронных сетей:
 - «TensorFlow»,
 - «Scikit-learn».
- Реализация интерфейса:
 - «Tkinter».



Архитектура ПО



Прогнозирование свойств

ПРОГНОЗИРОВАНИЕ СВОЙСТВ

Процентный состав

Ni	65	Cr	22.5	Co		W		Mo	9.5	Ti		Al		C	0.02
V		Ta		Nb	1	Si	1	Mn		Fe	0.49	Ce	0.49	Cu	
Be		B		S		La		Sn		Очистить состав		Выполнить прогноз			

Прогноз

g	7.92921	(г/см^3)	E	114.39495	(ГПа)
HV10	198.22326	(кгс/мм^2)	Rm	81.49405	(МПа)
Rp0.2	346.37084	(МПа)	A5	23.62325	(%)
КТР20-600	13.61605	(10^(-6)/К)	КТР25-500	12.74746	(10^(-6)/К)

Вычислительный эксперимент

НОМЕР	АУГМЕНТАЦИЯ	АРХИТЕКТУРА					РЕЗУЛЬТАТ
		Кол-во нейронов в слое	Кол-во эпох	Размер батча	Dropout	Скорость обучения	MSE
							MAE
1	НЕТ	256 - 128 - 64 - 32	100	32	НЕТ	0.001	1,4127
							0,781725
2	НЕТ	256 - 128 - 64 - 32	100	32	0.2 - 0.3 - 0.4 - 0.5	0.001	0,8543875
							0,6968
3	НЕТ	256 - 128 - 64 - 32	100	32	0.2 - 0.3 - 0.4 - 0.5	0.0001	0,9861375
							0,781
4	НЕТ	256 - 128 - 64 - 32	200	32	0.2 - 0.3 - 0.4 - 0.5	0.001	0,8227875
							0,6867625
5	НЕТ	256 - 128 - 64 - 32	100	64	0.2 - 0.3 - 0.4 - 0.5	0.001	1,0327625
							0,7475625
6	НЕТ	256 - 128 - 64	100	32	0.2 - 0.3 - 0.4	0.001	1,2120375
							0,736525
7	800 + 200 (+/- 0.01)	256 - 128 - 64 - 32	100	32	0.2 - 0.3 - 0.4 - 0.5	0.001	0,660475
							0,4879875
8	2000 + 500 (+/- 0.01)	256 - 128 - 64 - 32	100	32	0.2 - 0.3 - 0.4 - 0.5	0.001	0,7057875
							0,4617375
9	2000 + 500 (+/- 0.1)	256 - 128 - 64 - 32	100	32	0.2 - 0.3 - 0.4 - 0.5	0.001	0,7592375
							0,5018625
10	2000 + 500 (+/- 1)	256 - 128 - 64 - 32	100	32	0.2 - 0.3 - 0.4 - 0.5	0.001	0,7228
							0,4927875
11	2000 + 500 (+/- 0.01)	256 - 128 - 64 - 32	50	16	0.2 - 0.3 - 0.4 - 0.5	0.001	0,7008375
							0,477925
12	3200 + 800 (+/- 0.01)	256 - 128 - 64 - 32	100	32	0.2 - 0.3 - 0.4 - 0.5	0.001	0,7892
							0,4967

В результате выполнения ВКР были решены следующие задачи:

1. Проведен анализ предметной области и существующих программных решений для прогнозирования свойств композитов: «JMatPro», «Thermo-Calc» и «Ansys GRANTA»; выявлены их ограничения и обусловлена актуальность разработки нового;
2. Для решения задачи регрессии был проведен анализ таких методов, как: множественная линейная регрессия, метод опорных векторов, случайный лес и искусственная нейронная сеть. Наиболее подходящим для задачи «состав-свойство» является метод ИНС;
3. Разработано алгоритмическое и программное обеспечение ансамбля глубоких ИНС для прогнозирования физико-механических свойств на основе химического состава;
4. Вычислительные эксперименты показали хорошие метрики модели и прогнозов физико-механических свойств, а тестирование и оценка качества разработанного ПО – возможность его применения в исследовательской деятельности.